

BRIEFING DO PROJETO INTEGRADOR

Disciplina: Hands-On Fundamentos de Dados e Analytics
Módulo 1 – MBA em Engenharia de Dados – Universidade Presbiteriana Mackenzie
Mentoria: Prof. Gustavo Ferreira

1. IDENTIFICAÇÃO DO GRUPO

Nome do Projeto: _____

Sector de Atuação: Transporte aéreo, turismo e viagens

Nome completo	E-mail	LinkedIn
Agnes Ruescas	agnes.ruescas@outlook.com	https://br.linkedin.com/in/agnesruescas
Adriano Carvalho dos Santos	drico.dos.santo@gmail.com	https://www.linkedin.com/in/drico2236/
Brunno Souza de Mambro Santos	brunno_mambro@hotmail.com	https://www.linkedin.com/in/brunno-mambro-232639b3/
Gustavo de Paula Sousa	sr.depaula.gustavo@gmail.com	https://www.linkedin.com/in/gustavodepaulades/
Raul Chavarria	raul.chavarria.1977@gmail.com	https://www.linkedin.com/in/raulchavarria/
Santina Cortinove	santinacortinove@hotmail.com	https://www.linkedin.com/in/santina-cortinove-362bb9161/

2. DESCRIÇÃO DO PROBLEMA DE NEGÓCIO

2.1 Qual é o problema que vocês pretendem resolver?

Passageiros tomam decisões de compra de passagens aéreas com informações fragmentadas e, muitas vezes, sem referência histórica suficiente para avaliar se o preço encontrado é vantajoso. Além da incerteza sobre comprar naquele momento ou aguardar uma possível redução de tarifa, a escolha baseada apenas no menor preço pode desconsiderar fatores relevantes da experiência de viagem, como histórico de atrasos e cancelamentos da companhia, duração total do voo e quantidade de escalas. O projeto busca integrar essas dimensões em uma solução analítica única, capaz de apoiar uma decisão de compra mais informada.

2.2 Qual é o impacto do problema para o negócio?

A ausência de informações integradas sobre preço, antecedência de compra e confiabilidade operacional pode levar o passageiro a pagar mais pela passagem ou escolher voos com maior risco de atraso e cancelamento. Para plataformas de venda e empresas do setor, isso pode reduzir satisfação, confiança, conversão e fidelização, além de elevar reclamações e custos de atendimento. O projeto pretende tangibilizar esse impacto por meio da economia potencial associada às recomendações, da variação de preços por antecedência e rota e dos indicadores históricos de atraso e cancelamento.

3. OBJETIVOS DO PROJETO

3.1 Objetivo Geral

Desenvolver uma solução de dados para apoiar a decisão de compra de passagens aéreas nacionais, integrando cotações de preços coletadas periodicamente e dados históricos de voos da ANAC em uma arquitetura Lakehouse, a fim de analisar o comportamento dos preços por antecedência, estimar sua evolução por meio de regressão e séries temporais e recomendar ao usuário se o momento é favorável para comprar, aguardar ou monitorar, complementando a recomendação com indicadores históricos de confiabilidade operacional das companhias aéreas.

3.2 Objetivos Específicos

- Desenvolver uma rotina de coleta automatizada em Python para obter periodicamente cotações de passagens aéreas, considerando rota, companhia, datas, horários, duração, escalas e diferentes antecedências de compra.
- Implementar um MVP com conjunto reduzido de rotas relevantes (estimativa inicial de 10 a 30 rotas), mantendo a expansão para aproximadamente 510 trechos nacionais diretos como evolução futura.
- Construir uma arquitetura Lakehouse no Databricks Free Edition, utilizando as camadas Bronze, Silver e Gold para ingestão, tratamento, armazenamento e disponibilização dos dados.

- Construir um histórico de preços por rota, companhia e antecedência e analisar padrões de variação, sazonalidade e faixas historicamente mais vantajosas.
- Utilizar dados da ANAC para calcular indicadores de atrasos e cancelamentos e produzir um ranking de confiabilidade operacional por companhia e, quando possível, por rota.
- Desenvolver e comparar abordagens de regressão e séries temporais para estimar preço futuro ou variação esperada da tarifa.
- Aplicar uma regra de decisão sobre as previsões para gerar recomendações de COMPRAR, AGUARDAR ou MONITORAR.
- Apresentar os resultados em dashboard com preço atual, histórico, tendência/previsão, recomendação e indicadores de confiabilidade.

4. DADOS UTILIZADOS

4.1 Fontes de Dados

- Cotações de passagens aéreas coletadas periodicamente por scripts em Python.
- Dados abertos da Agência Nacional de Aviação Civil (ANAC), principalmente a base Voo Regular Ativo (VRA).

4.2 Escopo da Base

Número de registros: a definir após o início das coletas e ingestão dos arquivos ANAC. Serão gerados múltiplos registros por rota, companhia, data/hora de consulta, data/hora do voo e antecedência.

Escopo inicial: MVP de 10 a 30 rotas relevantes, priorizando profundidade histórica e recorrência de coleta; expansão futura para aproximadamente 510 trechos diretos.

Período coberto: histórico recente disponível na ANAC e cotações coletadas durante o desenvolvimento do projeto.

4.3 Dados Mapeados Atualmente

Base / conjunto	Principais dados mapeados	Aplicação no projeto
SoR_microdados	Microdados relacionados à operação aérea	Base analítica para exploração e integração dos dados
SoR_municipios	Informações de municípios	Enriquecimento e padronização geográfica
SoR_origens_destino	Origem, destino e informações relacionadas aos trechos	Identificação e análise das rotas
SoR_tarifas_aereas	Informações históricas de tarifas aéreas	Análise de preços, regressão e séries temporais
SoR_voos_operacoes	Informações sobre voos e operações	Análise operacional e integração com as demais bases

5. ARQUITETURA E GOVERNANÇA

5.1 Desenho da Arquitetura

Etapas	Fluxo / Conteúdo
FONTES	Python de cotações + dados abertos ANAC/VRA
INGESTÃO	Carga incremental no Databricks
BRONZE / RAW	JSON/CSV e tabelas Delta preservando dados brutos
SILVER / TRUSTED	Limpeza, padronização, deduplicação, tratamento de nulos e feature engineering
GOLD / CURATED	Histórico de preços, KPIs ANAC e datasets preparados para modelagem
MODELAGEM	Regressão multivariada + forecasting de séries temporais
DECISÃO	Combinação dos resultados e regra Comprar / Aguardar / Monitorar
CONSUMO	Databricks AI/BI Dashboard + indicadores e recomendações

5.2 Simulação das Camadas de Dados

Camada	Ferramenta/Formato	Conteúdo
Bronze / Raw	JSON/CSV + Delta	Cotações originais do Python e arquivos VRA da ANAC,

		preservados sem alterações funcionais.
Silver / Trusted	PySpark + Databricks SQL + Delta Lake	Datas, preços, aeroportos e companhias padronizados; duplicidades, nulos e inválidos tratados; variáveis derivadas.
Gold / Curated	PySpark + Spark SQL + MLflow + Delta	Curvas de preço, features, previsões, recomendação, melhores ofertas e ranking de confiabilidade.

5.3 Princípios de Governança Aplicados

- ☒ Catálogo e dicionário de dados
- ☒ Políticas de acesso (simulado)
- ☒ LGPD (simulado; sem necessidade de dados pessoais no MVP)
- ☒ Classificação de sensibilidade e rastreabilidade das fontes
- ☒ Versionamento de código, notebooks e modelos no repositório do projeto

6. ANÁLISE EXPLORATÓRIA

6.1 Técnicas previstas

- ☒ Estatística descritiva
- ☒ Visualização gráfica
- ☒ Detecção de outliers
- ☒ Correlação entre variáveis
- ☒ Análise de sazonalidade e tendência
- ☒ Análise por rota, companhia e antecedência
- ☒ Distribuição de atrasos e cancelamentos

6.2 Ferramentas previstas

- ☒ Python (Pandas / Matplotlib)
- ☒ PySpark / Spark SQL
- ☒ Databricks SQL
- ☒ Databricks AI/BI Dashboard
- ☒ MLflow para rastreamento dos experimentos

7. MODELAGEM PREDITIVA

7.1 Tipo de problema modelado

Previsão de valores contínuos (regressão), utilizando duas abordagens complementares: regressão multivariada e forecasting de séries temporais. A regressão permitirá estimar preço/variação considerando características do voo e da compra; as séries temporais permitirão capturar evolução, tendência e sazonalidade dos preços ao longo das coletas.

7.2 Estratégia de Modelagem

Frente	Objetivo	Entradas principais	Modelos candidatos
Regressão	Estimar preço futuro ou variação esperada considerando múltiplos fatores.	Rota, companhia, antecedência, dia da semana, mês, horário, duração, escalas, preço atual e histórico.	Regressão Linear (baseline), Random Forest Regressor e Gradient Boosting/XGBoost, se viável.
Séries temporais	Prever evolução do preço e capturar tendência/sazonalidade por rota ou agrupamento.	Sequência histórica de preços, data/hora da coleta e antecedência.	Baseline temporal + ARIMA/SARIMA e/ou Prophet, conforme volume e qualidade dos dados.

7.3 Variável-alvo e validação

Target principal: preço futuro ou variação percentual do preço em uma janela futura definida durante a exploração dos dados. A validação deverá respeitar a ordem temporal, evitando embaralhamento aleatório que provoque vazamento de informação. Métricas principais: MAE e RMSE; R^2 será utilizado como métrica complementar nos modelos de regressão.

7.4 Regra de Recomendação

A recomendação final será uma camada de decisão posterior às previsões. Como regra inicial de negócio, sujeita a calibração após a análise dos dados: COMPRAR quando houver expectativa relevante de aumento; AGUARDAR quando houver expectativa relevante de queda; MONITORAR quando a variação prevista estiver em uma faixa neutra. Um limiar inicial de $\pm 5\%$ poderá ser testado e ajustado conforme os resultados.

8. DASHBOARD FINAL

8.1 Ferramenta

Databricks AI/BI Dashboard.

8.2 Público-alvo

Usuários interessados em apoio à decisão de compra e stakeholders acadêmicos/técnicos responsáveis pela avaliação da solução.

8.3 Principais KPIs e saídas

KPI / Saída	Descrição	Insight esperado
Preço atual	Última cotação disponível para rota/voo.	Referência para decisão.
Preço médio histórico	Média histórica por rota e janela de antecedência.	Indicar se preço atual está acima/abaixo do padrão.
Variação prevista	Mudança esperada de preço.	Tendência de alta/queda.
Recomendação	Comprar / Aguardar / Monitorar.	Síntese acionável.
MAE / RMSE	Erro dos modelos preditivos.	Qualidade da previsão.
Taxa de atraso	Percentual histórico de atrasos.	Confiabilidade operacional.
Taxa de cancelamento	Percentual histórico de cancelamentos.	Risco operacional.
Ranking de confiabilidade	Comparativo entre companhias.	Complementar decisão além do preço.

9. PLANO DE EXECUÇÃO E PRAZOS

Cronograma relativo, a ser convertido em datas fechadas de acordo com a data oficial de entrega da disciplina.

Fase	Atividade	Entregável	Prazo
1	Refinar escopo, MVP, rotas e fontes	Briefing V2 + escopo fechado	Semana 1
2	Mapear variáveis e arquitetura	Dicionário + desenho de arquitetura	Semana 1
3	Desenvolver Python e ingerir ANAC	Scripts Python de coleta + base ANAC no Databricks	Semana 2
4	Construir Bronze e Silver	Dados brutos e tratados	Semanas 2-3
5	Realizar EDA e feature engineering	Análise exploratória + dataset ML	Semana 3
6	Criar baseline e modelos de regressão	Modelos + métricas	Semana 4
7	Modelar séries temporais	Forecast + métricas	Semana 4
8	Comparar/combinar resultados	Estratégia final + regra de decisão	Semana 5
9	Construir Gold e KPIs ANAC	Tabelas finais	Semana 5
10	Desenvolver dashboard	Dashboard funcional	Semana 6
11	Testar e validar ponta a ponta	MVP validado	Semana 6
12	Documentar e preparar apresentação	GitHub + README + slides	Semana 7

10. KANBAN DO PROJETO

Fluxo sugerido: BACKLOG → TO DO → DOING → REVIEW/TESTES → DONE. Cada card deverá conter responsável, prazo e critério de aceite.

Backlog inicial	Critério de aceite resumido
-----------------	-----------------------------

Definir rotas do MVP	Lista de 10-30 rotas aprovada pelo grupo
Definir frequência e campos do Python	Periodicidade e schema documentados
Criar dicionário de dados	Variáveis, tipos, fontes e tratamentos definidos
Desenhar arquitetura	Fluxo Bronze/Silver/Gold + ML + dashboard validado
Desenvolver Python	Scripts Python executando a coleta e persistindo os dados
Ingerir ANAC/VRA	Dados disponíveis na Bronze
Criar Silver	Dados limpos, padronizados e deduplicados
Executar EDA	Principais padrões, outliers e sazonalidade documentados
Feature engineering	Dataset de modelagem pronto
Treinar regressão	Baseline e modelos comparados
Treinar séries temporais	Forecast e métricas documentados
Definir regra de decisão	Comprar/Aguardar/Monitorar implementado
Criar Gold	Outputs analíticos e preditivos disponíveis
Criar KPIs ANAC	Atraso, cancelamento e ranking calculados
Criar dashboard	Visões e filtros principais funcionando
Documentar GitHub	README, código, notebooks e artefatos organizados
Preparar apresentação	Narrativa, resultados e aprendizados finalizados

11. CRITÉRIOS DE SUCESSO

- ☒ Pipeline executa da ingestão à camada Gold sem erros críticos.
- ☒ Dados do Python e da ANAC são tratados e disponibilizados com dicionário de dados documentado.
- ☒ Modelos de regressão e séries temporais possuem métricas registradas e comparação com baseline.
- ☒ Validação temporal é aplicada para evitar data leakage.
- ☒ Recomendação Comprar/Aguardar/Monitorar é gerada para as rotas do MVP.
- ☒ Dashboard apresenta histórico, previsão/tendência, recomendação e confiabilidade operacional.
- ☒ Repositório contém README, código-fonte, notebooks e documentação necessária para reprodução do MVP.

12. DOCUMENTAÇÃO E APRESENTAÇÃO FINAL

Repositório GitHub do projeto: _____

- ☒ README com visão geral e arquitetura
- ☒ Código-fonte (Python, SQL etc.)
- ☒ Notebooks de EDA e modelagem
- ☒ Documentação do Python e dicionário de dados
- ☒ Slides de apresentação
- ☒ Artefatos complementares (JSON/CSV, quando aplicável)

12.1 Observações e aprendizados do grupo

Registrar ao final do projeto os principais desafios técnicos, decisões de escopo, limitações dos dados, resultados dos modelos, aprendizados e possíveis evoluções da solução.